



FPT SCHOOL OF BUSINESS & TECHNOLOGY

FruitStoreChatbotAI: Chatbot bán trái cây tích hợp Facebook Messenger sử dụng RAG, Zero-shot Routing và LLM Rewrite

Nguyễn Thanh Bình, Mai Văn An, Phạm Đình Hoàng, Nguyễn Tuấn Dũng
FPT School of Business & Technology

Tóm tắt nội dung

Bài báo trình bày FruitStoreChatbotAI, hệ thống chatbot hỗ trợ cửa hàng trái cây trên web và Facebook Messenger. Dự án tách thành admin-service cho quản trị sản phẩm/tồn kho và chatbot-service cho hội thoại, recommendation, FAQ, webhook Messenger và lớp AI. Chatbot-service bắt buộc sử dụng pretrained zero-shot router, BGE-M3 embedding, BGE reranker và LM Studio; các thành phần được kiểm tra theo cơ chế fail-fast trước khi service nhận traffic. Rule guard, agent nghiệp vụ và database vẫn giữ quyền kiểm soát intent cuối, giá, tồn kho và chính sách. Thiết kế này kết hợp khả năng hiểu ngôn ngữ tự nhiên với độ chính xác dữ kiện cần thiết cho bán hàng.

Từ khóa: chatbot bán hàng, RAG, zero-shot classification, semantic search, FastAPI, Messenger, LM Studio.

1 Giới thiệu

Fanpage bán trái cây thường nhận nhiều câu hỏi lặp lại: hôm nay có gì, giá bao nhiêu, còn hàng không, nên mua loại nào, ship bao lâu và đổi trả thế nào. Dữ liệu lại thay đổi nhanh theo tồn kho, giá nhập và mùa vụ. Nếu dùng rule-only, chatbot khó hiểu câu hỏi tự nhiên; nếu dùng LLM trực tiếp, bot có thể bịa giá hoặc bịa tồn kho.

FruitStoreChatbotAI dùng hướng hybrid: dữ liệu sản phẩm/FAQ là nguồn chân lý, agent nghiệp vụ tạo câu trả lời nền, còn deep learning hỗ trợ hiểu intent, truy xuất ngữ nghĩa, rerank và viết lại câu trả lời. Mục tiêu là bot trả lời tự nhiên nhưng vẫn kiểm soát được dữ kiện.

1.1 Đóng góp chính


- Tách hai service: admin-service cho vận hành nội bộ và chatbot-service cho Messenger.
- Pretrained zero-shot router chạy cho mọi input; heuristic/rule guard và labeled examples bảo vệ intent nghiệp vụ.
- RAG bắt buộc dùng BGE-M3 embedding và BGE reranker; recommendation dựa trên vị, dinh dưỡng, ngân sách và mục đích dùng.
- Webhook Facebook Messenger, Graph API, ngrok trong môi trường phát triển.
- ETA giao hàng theo khu vực Hà Nội, cộng buffer chuẩn bị đơn và hỗ trợ LLM resolver cho địa chỉ khó.
- Fail-fast, /health, /ai/status và frontend readiness ngăn người dùng gửi tin khi AI runtime chưa sẵn sàng.

Bảng 1: Stack công nghệ chính

Nhóm	Công nghệ và vai trò
Backend	FastAPI, Uvicorn, Pydantic v2, SQLAlchemy ORM.
Dữ liệu	SQLite prototype; có thể nâng cấp PostgreSQL.
AI/NLP	Zero-shot router, BGE-M3 embedding và BGE reranker bắt buộc.
LLM	LM Studio bắt buộc qua OpenAI-compatible chat completions.
Messenger	Facebook Graph API, webhook verify, Send API, ngrok HTTPS.
Frontend	Next.js, React, Tailwind CSS, Framer Motion.
DevOps	Docker Compose, cấu hình qua env/secret file.

2 Kiến trúc hệ thống

Hệ thống gồm hai service dùng chung database SQLite trong prototype. Admin-service chạy cổng 8000 để đăng nhập, quản trị sản phẩm, cập nhật tồn kho và audit; service này dùng `build_services=False` nên không tải model AI. Chatbot-service chạy cổng 8001 để xử lý chat, recommendation, FAQ, inventory/products API và Messenger webhook. Khi startup, chatbot-service probe LM Studio, tải BGE-M3 embedding, BGE reranker, dựng index và tải router; thiếu một thành phần bắt buộc sẽ làm startup thất bại. Khi admin cập nhật dữ liệu, bảng `inventory_events` tăng revision; request chat kế tiếp sẽ rebuild retriever index và invalidate cache.




Hình 1: Kiến trúc tổng thể theo luồng dọc.

3 Dữ liệu và snapshot

Sản phẩm lưu nhiều thuộc tính ngoài tên, giá và tồn kho: độ ngọt, độ chua, mức hạt, độ mọng nước, mùi thơm, độ giòn, vitamin C, chất xơ, đường tự nhiên, calo, texture, best-use, nguồn gốc, mùa vụ và thời gian bảo quản. Các trường này giúp recommendation agent tư vấn theo nhu cầu cụ thể.

Bảng 2: Snapshot số liệu dự án


Hạng mục	SL	Ghi chú
Sản phẩm	14	Dữ liệu tư vấn chính.
FAQ	3	Shipping, return, storage.
Inventory events	19	Audit cập nhật kho.
Conversation messages	368	Lịch sử demo/dev.
Khu vực ETA	12	Hà Nội, xuất phát Nam Từ Liêm.
Intent hỗ trợ	11	RouterAgent.
API routes	13	Admin, AI status, chat, webhook, products.
Source files	57	Backend, frontend, tools.
Source lines	12.402	Snapshot ngày 07/06/2026.



Hình 2: Phân bố dòng code theo module chính.

4 Pipeline chatbot

Luồng chính nằm trong `handle_chat_request`. Hệ thống không giao quyền quyết định nghiệp vụ cho LLM; agent tạo câu trả lời nền bằng dữ liệu thật, LLM chỉ rewrite câu cuối, sau đó guard kiểm tra lại.



Hình 3: Pipeline xử lý một câu hỏi khách hàng.

4.1 Router nhiều lớp

RouterAgent hỗ trợ 11 intent: greeting, available_products, price_general, inventory_check, recommendation, order_support, faq_shipping, faq_return, faq_storage, admin_update_stock và out_of_domain. Pretrained semantic backend được gọi ngay đầu hàm route cho mọi câu hỏi. Kết quả zero-shot được giữ lại, nhưng heuristic/rule và labeled examples có thể ghi đè khi có tín hiệu nghiệp vụ rõ; nếu không có lớp chắc chắn hơn, kết quả pretrained đạt ngưỡng được dùng.

Bảng 3: Một số intent chính

Intent	Luồng xử lý
inventory_check	Hỏi giá/tồn kho; tìm sản phẩm và trả dữ liệu thật.
price_general	Hỏi giá chung; trả bảng giá nhanh nếu chưa có entity.
recommendation	Parse nhu cầu, ngân sách, khẩu vị; rank sản phẩm.
faq_shipping	Trả FAQ hoặc ETA khu vực giao hàng.
order_support	Tạm tính đơn khi có nhiều sản phẩm/số lượng.
out_of_domain	Hướng người dùng về phạm vi shop trái cây.

4.2 RAG và recommendation

HybridRetriever xây index in-memory từ products và FAQ bằng BAAI/bge-m3. Câu hỏi và document được mã hóa thành vector; truy xuất ban đầu dùng cosine similarity:

$$s(q, d) = \frac{\mathbf{v}_q \cdot \mathbf{v}_d}{\|\mathbf{v}_q\| \|\mathbf{v}_d\|} \quad (1)$$

RecommendationAgent parse constraint như ngọt, ít chua, ít đường, vitamin C, ít hạt, texture, đối tượng dùng và ngân sách. Điểm tư vấn có dạng:

$$R(p, q) = \alpha P(p, c) + \beta S(p, q) + \gamma B(p, b) \quad (2)$$

trong đó P là điểm thuộc tính, S là semantic relevance và B là điểm ngân sách.

Candidate pool sau vector search bắt buộc được xếp hạng lại bằng BAAI/bge-reranker-v2-m3. Hệ thống không còn hashing fallback hoặc chế độ bỏ qua reranker; lỗi tải model hay inference được báo rõ để tránh âm thầm chạy ở chất lượng thấp.

4.3 LLM rewrite và guard


ResponseRewriter bắt buộc gọi LM Studio qua OpenAI-compatible chat completions. Khi startup, code gọi `/v1/models`, xác nhận hoặc tự chọn model chat/instruct và gửi một completion probe. Prompt yêu cầu tiếng Việt có dấu, tối đa hai câu, trả lời trực tiếp và không bịa dữ kiện. Mọi chat response và Messenger postback phải rewrite thành công; lỗi LM Studio làm API trả 503 thay vì quay về câu nền. Sau rewrite, guard kiểm tra entity, giá và ngân sách; nếu lệch, hệ thống sửa bằng dữ liệu products/constraints.

5 ETA giao hàng

Module `delivery_eta.py` hỗ trợ 12 khu vực Hà Nội, xuất phát từ Nam Từ Liêm. Mỗi khu vực có khoảng thời gian di chuyển và alias địa danh. ETA được tính:

$$ETA(area) = Travel(area) + 30 \text{ phút} \quad (3)$$

Nếu rule không khớp nhưng câu hỏi có dấu hiệu địa chỉ, LLM resolver phân loại địa chỉ về khu vực cho phép. Kết quả chỉ được nhận khi confidence tối thiểu 0,65.



Hình 4: ETA tối đa sau khi cộng 30 phút chuẩn bị đơn.

6 Messenger webhook

Meta gọi GET /webhooks/facebook để verify webhook bằng FACEBOOK_VERIFY_TOKEN. Khi người dùng nhấn tin, Meta gửi POST /webhooks/facebook; service kiểm tra chữ ký nếu có FACEBOOK_APP_SECRET, bỏ qua echo message, lấy PSID làm user/session, gọi handle_chat_request, rồi gửi reply qua Graph API Send API.

Bảng 4: Biến môi trường quan trọng

Biến	Mục đích
FACEBOOK_VERIFY_TOKEN	Verify webhook.
FACEBOOK_PAGE_ACCESS_TOKEN	Gửi reply qua Graph API.
FACEBOOK_APP_SECRET	Xác minh chữ ký webhook.
LM_STUDIO_BASE_URL	Endpoint LM Studio bắt buộc; local dùng localhost, Docker dùng host.docker.internal.
USE_PRETRAINED_INTENT_ROUTER	Phải là true; service từ chối startup nếu tắt.
PRETRAINED_INTENT_*	Cấu hình zero-shot router, mặc định xlm-roberta-large-xnli.
EMBEDDING_MODEL_NAME	BGE-M3 embedding bắt buộc cho RAG.
PRETRAINED_RERANKER_*	BGE reranker bắt buộc cho candidate pool.

7 Vận hành, bảo mật và quan sát

Admin-service dùng đăng nhập riêng, cấp token Bearer và bảo vệ các endpoint cập nhật sản phẩm/tồn kho. API update-stock dùng Idempotency-Key để tránh áp dụng trùng request; rate limit giúp giảm thao tác lặp quá nhanh. Các secret như Page Access Token, App Secret, verify token và endpoint LM Studio được đặt qua biến môi trường, không đưa vào source code.


Chatbot-service dùng fail-fast: router, embedding, reranker và LM Studio phải sẵn sàng trước khi startup hoàn tất. Endpoint /health trả 503 nếu AI runtime lỗi; /ai/status trả readiness và model của từng thành phần. Frontend kiểm tra endpoint này khi mở trang và mỗi 30 giây, đồng thời khóa ô nhập cùng quick replies khi runtime chưa sẵn sàng. Docker cài bộ requirements đầy đủ và dùng volume Hugging Face cache để tránh tải lại model.

Về quan sát hệ thống, chatbot ghi trace_id, intent, confidence, route_reason, route_input và rewrite mode vào log QA. Đây là dữ liệu quan trọng để xây bộ evaluation từ câu hỏi Messenger thật, phát hiện intent sai, mở rộng alias trái cây và kiểm thử lại prompt/model sau mỗi lần chỉnh.

8 Ví dụ và đánh giá

Bảng 5: Ví dụ input/output

Input	Output kỳ vọng
Cam Úc còn không?	Trà tồn kho và giá Cam Úc.
Trái nào ít chua dưới 100k?	Gợi ý 1-2 sản phẩm hợp ngân sách.
Mình lấy 2 táo và 1 cam	Tạm tính từng dòng hàng và tổng tiền.
Ship Duy Tân bao lâu?	ETA khu vực Cầu Giấy, cộng chuẩn bị đơn.
oi còn không	Hỏi lại để phân biệt quả ổi/trái lê.



Hình 5: Một số hạng mục chức năng trong snapshot hiện tại.

Hệ thống hiện ở mức prototype. Hạn chế chính là dữ liệu test intent chưa đủ lớn, SQLite chưa phù hợp khi có nhiều admin/page cùng ghi và webhook gửi reply đồng bộ. Kiến trúc pretrained AI bắt buộc cũng làm tăng thời gian startup, RAM/VRAM và phụ thuộc vận hành vào LM Studio; môi trường demo đầy đủ nên chuẩn bị khoảng 16 GB RAM. Hướng cải tiến gồm xây evaluation từ log Messenger, đo accuracy/factuality/latency, chuyển sang PostgreSQL, thêm queue cho Send API, theo dõi /health/ai/status và quản trị FAQ/alias trong admin UI.

9 Kết luận

FruitStoreChatbotAI là hệ thống chatbot bán hàng theo hướng thực dụng: tách service vận hành và service hội thoại, dùng database làm nguồn chân lý, bắt buộc pretrained AI cho routing/retrieval và dùng LM Studio để diễn đạt câu trả lời cuối. Rule guard, agent nghiệp vụ, fail-fast và readiness giúp giảm rủi ro bịa thông tin hoặc âm thầm hạ chất lượng khi model lỗi, trong khi vẫn giữ trải nghiệm tự nhiên trên web và Messenger.

Tài liệu

- [1] FastAPI Documentation, <https://fastapi.tiangolo.com/>.
- [2] Meta for Developers, Messenger Platform Webhooks and Send API, <https://developers.facebook.com/docs/messenger-platform/>.
- [3] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," NeurIPS, 2020.
- [4] Y. Yin, J. Hay, and D. Roth, "Benchmarking Zero-shot Text Classification," EMNLP, 2019.
- [5] BAAI, BGE Embedding Models, <https://huggingface.co/BAAI>.